



**SKRIPSI**

**PREDIKSI NILAI TUKAR MATA UANG RUPIAH  
TERHADAP DOLAR AMERIKA MENGGUNAKAN  
METODE BI-LSTM-AM**

**MUHAMMAD ABDULLAH HAFIZH**

**NPM 21081010099**

**DOSEN PEMBIMBING**

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI INFORMATIKA  
SURABAYA  
2024**



**SKRIPSI**

**PREDIKSI NILAI TUKAR MATA UANG RUPIAH  
TERHADAP DOLAR AMERIKA MENGGUNAKAN  
METODE BI-LSTM-AM**

**MUHAMMAD ABDULLAH HAFIZH**

**NPM 21081010099**

**DOSEN PEMBIMBING**

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI  
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR  
FAKULTAS ILMU KOMPUTER  
PROGRAM STUDI INFORMATIKA  
SURABAYA  
2024**

## LEMBAR PENGESAHAN

### PREDIKSI NILAI TUKAR MATA UANG RUPIAH TERHADAP DOLAR AMERIKA MENGGUNAKAN METODE BI-LSTM

Oleh:

MUHAMMAD ABDULLAH HAFIZH  
NPM. 21081010099

Telah dipertahankan dihadapan dan diterima oleh Tim Penguji Skripsi Prodi Informatika Fakultas Ilmu Komputer Universitas Pembangunan Nasional Veteran Jawa Timur pada tanggal.....

Menyetujui,

Nama Dosen

NIP / NPT

..... ( Pembimbing I )

Nama Dosen

NIP / NPT

..... ( Pembimbing II )

Nama Dosen

NIP / NPT

..... ( Ketua Penguji )

Nama Dosen

NIP / NPT

..... ( Anggota Penguji II )

Mengetahui,

Dekan Fakultas Ilmu Komputer

Prof. Dr. Ir. Novirina Hendrasarie, MT

NIP. 19681126 199403 2 001

## LEMBAR PERSETUJUAN

### PREDIKSI NILAI TUKAR MATA UANG RUPIAH TERHADAP DOLAR AMERIKA MENGGUNAKAN METODE BI-LSTM

Oleh:

MUHAMMAD ABDULLAH HAFIZH  
NPM. 21081010099

Telah disetujui untuk mengikuti Ujian Skripsi

Menyetujui,

Dosen Pembimbing I

Dosen Pembimbing II

Nama Dosen  
NIP

Nama Dosen  
NIP

Koordinator Skripsi

Prodi Informatika Fakultas Ilmu Komputer

Andreas Nugroho Sihananto, S. Kom., M. Kom.

NIP. 199004122024061003

## **SURAT PERNYATAAN ORISINALITAS**

Yang bertanda tangan di bawah ini:

Nama mahasiswa / NPM : Muhammad Abdullah Hafizh / 21081010099  
Program Studi : Informatika  
Dosen Pembimbing :

dengan ini menyatakan bahwa Skripsi dengan judul “PREDIKSI NILAI TUKAR MATA UANG RUPIAH TERHADAP DOLAR AMERIKA MENGGUNAKAN METODE BI-LSTM” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Universitas Pembangunan Nasional Veteran Jawa Timur.

Surabaya, .....

Mahasiswa

**(Muhammad Abdullah Hafizh)**

**NPM. 21081010099**

## **ABSTRAK**

## ABSTRACT

## **KATA PENGANTAR**



## **DAFTAR ISI**

## DAFTAR TABEL

## **DAFTAR GAMBAR**

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang**

Kurs adalah rasio nilai tukar antara mata uang suatu negara dengan mata uang asing lainnya, yang berfungsi sebagai indikator penting dalam perekonomian global. Nilai tukar ini menunjukkan harga satu unit mata uang dalam bentuk unit mata uang lainnya dan ditentukan di pasar valuta asing, yang menjadi tempat perdagangan berbagai mata uang. Pasar ini beroperasi secara dinamis, dipengaruhi oleh berbagai faktor seperti permintaan dan penawaran, kondisi ekonomi, serta kebijakan moneter dari negara-negara yang terlibat. Nilai tukar tidak hanya berfungsi sebagai alat tukar dalam transaksi internasional, tetapi juga dapat dijadikan sebuah indikator untuk menilai kondisi perekonomian suatu negara. Sebuah mata uang yang stabil mencerminkan perekonomian yang relatif baik dan terjaga, menunjukkan bahwa negara tersebut memiliki kontrol yang baik terhadap inflasi dan pertumbuhan ekonomi, serta kepercayaan dari investor asing [1].

Dalam konteks perdagangan internasional, terutama pada sektor ekspor dan impor, nilai tukar terhadap dolar Amerika memiliki dampak yang signifikan, mengingat posisi dolar Amerika sebagai mata uang internasional yang paling banyak digunakan dalam transaksi global. Ketika nilai tukar melemah, kegiatan ekspor berpotensi meningkat karena barang-barang dari negara tersebut menjadi lebih murah bagi pembeli asing, sehingga meningkatkan daya saing produk di pasar internasional. Sebaliknya, ketika nilai tukar menguat, kegiatan ekspor berpotensi menurun karena harga barang menjadi lebih mahal bagi pembeli luar negeri. Pada kegiatan impor, apabila nilai tukar melemah, maka kegiatan impor akan berpotensi menurun karena barang-barang dari luar negeri menjadi lebih mahal, sehingga konsumen cenderung mengurangi pembelian barang impor. Sebaliknya, jika nilai tukar menguat, kegiatan impor berpotensi meningkat karena barang-barang luar negeri menjadi lebih terjangkau bagi konsumen domestik [2].

Ketidakstabilan nilai tukar dapat memengaruhi aliran modal dan perdagangan internasional, mengingat transaksi ekonomi lintas negara melibatkan mata uang domestik dan asing. Ketidakpastian ini dapat menciptakan risiko bagi

pelaku ekonomi, termasuk perusahaan yang terlibat dalam perdagangan internasional. Nilai tukar rupiah mengalami ketidakstabilan selama beberapa tahun terakhir, dengan depresiasi yang signifikan sebesar 727,81% dari tahun 1990 hingga 2023. Nilai tukar terkuat terjadi pada tahun 1990, dengan nilai sebesar Rp1.842,81 per dolar AS, sementara itu, nilai tukar terlemah mencapai Rp15.225,05. Fluktuasi yang tajam ini menunjukkan tantangan yang dihadapi oleh perekonomian Indonesia dalam menjaga stabilitas mata uangnya di tengah dinamika ekonomi global yang terus berubah [1].

Tidak hanya sektor perdagangan internasional, nilai tukar rupiah juga berpengaruh terhadap sektor wisata dalam negeri. Dalam setiap transaksi, wisatawan diwajibkan menggunakan rupiah sebagai mata uang resmi di Indonesia, yang berarti bahwa nilai tukar rupiah dapat memengaruhi keputusan wisatawan asing untuk berkunjung. Hal ini mendorong pandangan bahwa nilai tukar rupiah memengaruhi jumlah kunjungan wisatawan asing, karena wisatawan perlu menukarkan mata uang asal mereka ke rupiah sebelum melakukan transaksi. Apabila nilai tukar rupiah mengalami penurunan, maka sektor wisata dapat mengalami peningkatan, karena wisatawan asing akan mendapatkan lebih banyak rupiah untuk setiap unit mata uang mereka, sehingga meningkatkan daya beli mereka di Indonesia. Namun, sebaliknya, apabila nilai tukar mengalami peningkatan, maka sektor wisata dapat mengalami penurunan, karena biaya untuk berlibur di Indonesia menjadi lebih mahal bagi wisatawan asing [3].

Ketidakstabilan yang terjadi pada nilai tukar rupiah terhadap dolar Amerika Serikat menunjukkan pentingnya prediksi nilai tukar untuk membantu pelaku ekonomi dalam mengambil keputusan yang tepat [4]. Memprediksi perubahan nilai tukar secara akurat dapat membantu dalam pengambilan keputusan terkait ekspor, impor, pengelolaan dana, serta mitigasi risiko mata uang. Dalam konteks ini, penting untuk mempertimbangkan berbagai faktor yang memengaruhi fluktuasi nilai tukar rupiah di luar nilai kurs itu sendiri [5]. Memprediksi nilai tukar membutuhkan variabel lain selain nilai tukar itu sendiri untuk meningkatkan akurasi prediksi. Variabel yang dapat memengaruhi fluktuasi mata uang termasuk nilai ekspor, nilai impor, dan nilai suku bunga. Suku bunga memiliki pengaruh positif namun tidak signifikan terhadap nilai tukar, sedangkan ekspor berpengaruh

positif dan signifikan terhadap stabilitas nilai tukar rupiah. Sementara itu, nilai impor berpengaruh positif namun tidak signifikan terhadap stabilitas nilai tukar rupiah [6], [7].

Metode untuk memprediksi nilai tukar terbagi menjadi tiga. Pertama, metode statistik seperti ARIMA, GARCH, dan VAR. Metode ini digunakan untuk data yang bersifat stasioner dan cenderung tidak akurat apabila data yang digunakan bersifat dinamis. Kedua, metode *machine learning* seperti CNN, ANN, SVR, GRU, dan RNN. Metode dengan pendekatan *machine learning* mengatasi kekurangan dari metode statistik, namun terdapat kekurangan dalam pengoptimalan *hyperparameter* sehingga menyebabkan *overfitting* atau *underfitting*. Ketiga, metode *hybrid*, yaitu menggabungkan dua metode atau lebih, seperti ARIMA untuk menentukan input dan mengkombinasikan ANN dan SVR untuk memprediksi nilai tukar. Selain itu metode *hybrid* lainnya seperti CNN dan Bi-LSTM atau GRU-LSTM telah digunakan dalam penelitian beberapa tahun terakhir [8].

Pada penelitian di tahun 2020 oleh Wenjie Lu, dkk menggunakan metode CNN-BiLSTM-AM untuk memprediksi Shanghai Stock Exchange Composite Index dari tanggal 1 Juli 1991 hingga 30 Juni 2020. Hasil pengujian dari penelitian ini menunjukkan nilai MAE 21.952, RMSE 31.694, dan  $R^2$  0.9804 [9]. Tidak hanya itu, pada penelitian tahun 2023 yang berjudul “A New LASSO-BiLSTM-Based Ensemble Learning Approach For Exchange Rate Forecasting” yang memprediksi nilai tukar mata uang CNY terhadap USD. Penelitian ini menunjukkan hasil MAE 0.051, RMSE 0.072, dan MDA 0.777.

## **1.2 Rumusan Masalah**

Dari latar belakang yang telah dijelaskan, maka dapat dipaparkan rumusan dari masalah yang akan dibahas dalam penelitian ini.

1. Bagaimana implementasi kombinasi metode CNN, BiLSTM, dan *Attention Mechanism* dalam memprediksi kurs IDR-USD.
2. Bagaimana keakurasian kombinasi CNN, BiLSTM, dan *Attention Mechanism* dalam memprediksi kurs IDR-USD.

## **1.3 Batasan Masalah**

Dalam penelitian ini, terdapat beberapa batasan yang perlu diperhatikan untuk memastikan fokus dan kejelasan dalam penelitian yang dilakukan.

1. Data yang digunakan adalah data harian dari 1 Januari 2015 hingga 31 Desember 2024.
2. Metrik pengujian penelitian ini menggunakan MSE, MAE, dan RMSE.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **2.1 Penelitian Terdahulu**

Penelitian ini didasarkan dari apa yang penulis temukan saat studi literatur dari beberapa penelitian terdahulu. Pada penelitian terdahulu terdapat kesimpulan yang bisa digunakan untuk referensi pada penelitian di masa depan. Berikut penelitian terdahulu yang berkaitan dengan topik penelitian ini.

Pada penelitian yang berjudul “*Prediksi Kurs Rupiah Terhadap Dolar dengan Menggunakan Model Long-Short-Term-Memory*”. Pada Penelitian ini menjelaskan bahwa penelitian ini menggunakan data dari situs JISDOR pada periode waktu 5 April 2018 hingga 26 Mei 2023. Dengan menggunakan Penelitian ini menggunakan metode LSTM berarsitektur 4 layer, yaitu 320, 416, 224, dan 128 neuron dengan *hyperparameter* pengujian dapat menghasilkan pengujian optimal yaitu MSE 0,0004 dan RMSE 0,0210. Penelitian ini juga membandingkan dengan metode statistik Autoregressive Integrated Moving Average (ARIMA). Pada metode ARIMA mendapatkan hasil MSE 0.0005 dan RMSE 0.0224 [5].

Pada penelitian tahun 2023 yang berjudul “Forecasting Stock Closing Prices With An Application To Airline Company Data”, penelitian ini menggunakan metode Least Absolute Shrinkage and Selection (LASSO) untuk memprediksi harga saham penutup dari tiga maskapai internasional. Penelitian ini menggunakan 15 fitur. Hasil pengujian menunjukkan bahwa metode lebih baik dibandingkan dengan metode Ridge Regresion, Tree Regression, Support Vector Machine, dan Multilayer Perception Neural Network. Dibuktikan dengan hasil MAPE 2.17% pada maskapai Air China, MAPE 1.94% pada maskapai China Eastern Airlines, dan MAPE 2.06% pada maskapai Chine Southern Airlines [10].

Pada penelitian yang berjudul “A New LASSO-BiLSTM-Based Ensemble Learning Approach For Exchange Rate Forecasting” yang dilakukan pada tahun 2023 menjelaskan bahwa metode LASSO (Least Absolute Shrinkage and Selection) dan BiLSTM (Bidirectional Long Short-Term Memory) dapat dikombinasikan untuk memprediksi kurs CNY terhadap USD. Metode LASSO digunakan untuk memilih fitur dari yang awalnya berjumlah 29 fitur yang berkorelasi dengan



aktivitas ekonomi, namun dengan metode LASSO terpilih enam fitur yang sangat berkorelasi dan juga digunakan untuk mengurangi *noise*. Metode BiLSTM digunakan untuk memprediksi nilai tukar berdasarkan enam fitur terpilih. Untuk menguji model ini, penulis membandingkan dengan empat model prediksi lainnya, yaitu ELM, KELM, LSTM, dan SVR. Hasil pengujian menunjukkan dengan menggunakan satu *timestep*, metode LASSO-BiLSTM unggul dengan MAE 0.051, RMSE 0.072, dan MDA 0.777. Hasil yang sama juga pada tiga dan enam *timestep*, bahwa LASSO-BiLSTM tetap unggul dibandingkan metode lainnya [8].


Pada penelitian tahun 2020 yang berjudul “A CNN-BiLSTM-AM Method For Stock Price Prediction”. Penelitian ini menggunakan set data yang diambil dari Shanghai Stock Exchange Composite Index periode waktu 1 Juli 1991 hingga 30 Juni 2020. Dengan total berjumlah 8 fitur, yaitu opening price, highest price, lowest price, closing price, volume, turnover, ups and downs, dan change. Metode CNN pada penelitiannya digunakan untuk ekstraksi fitur, BiLSTM untuk mempelajari dan memprediksi fitur, dan *Attention Mechanism* (AM) untuk menangkap hubungan fitur dalam deret waktu di waktu yang berbeda. Hasil pengujian dari penelitian ini menunjukkan nilai MAE 21.952, RMSE 31.694, dan R<sup>2</sup> 0.9804. Metode CNN-BiLSTM-AM unggul dibanding metode LSTM, BiLSTM, CNN-LSTM, CNN- BiLSTM, dan BiLSTM-AM [9].

## 2.2 Kurs

Kurs atau nilai tukar mata uang merupakan perbandingan nilai dari mata uang negara yang dinyatakan dalam mata uang negara lain. Kurs digunakan sebagai alat untuk mengkonversi berbagai harga mata uang dalam negeri kedalam mata uang asing. Kurs dapat berubah nilainya tergantung permintaan terhadap mata uang asing. Isitilah penambahan nilai suatu mata uang disebut apresiasi. Apresiasi mata uang terjadi karena daya tarik kuat antara permintaan dan penawaran pada pasar valuta asing. Sementara itu istilah dari penurunan nilai suatu mata uang disebut depresiasi. Depresiasi menyebabkan ekspor menjadi lebih murah dan impor menjadi lebih mahal

### 2.3 Time Series

Time series atau runtun waktu merupakan sekumpulan data yang diurutkan berdasarkan waktu. Time series digunakan untuk memprediksi dengan menganalisa pola hubungan antara variabel yang ingin diprediksi dan variabel waktu. Terdapat empat model data dalam prediksi time series, yaitu model horizontal, model tren, model musiman, dan model siklis [11]. Pola horizontal merupakan pola yang acak dan tidak terduga. Pola tren merupakan pola yang menunjukkan data dalam jangka panjang dapat berupa peningkatan atau penurunan. Pola musiman merupakan pola yang terjadi secara periode tertentu. Pola siklis yaitu pola yang menunjukkan ketidakstabilan data yang terjadi dalam periode waktu tertentu.



**Gambar II.1**

### 2.4 Artificial Neural Network

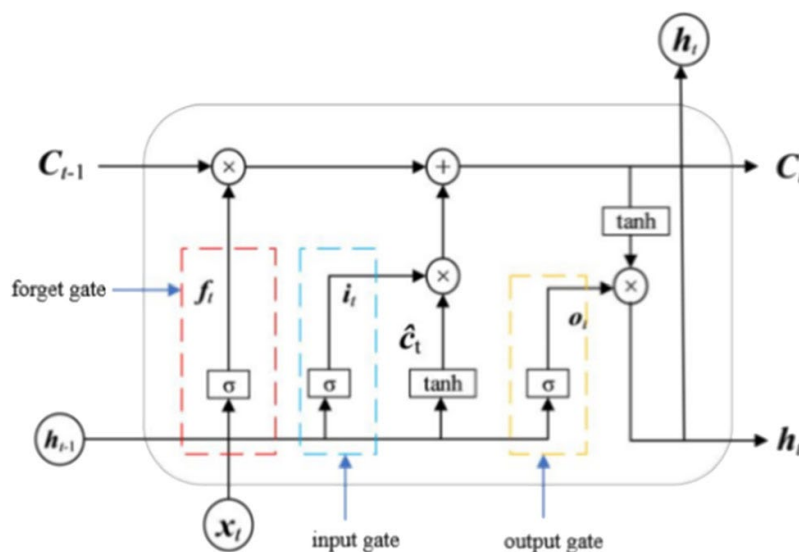
Artificial Neural Network (ANN) adalah algoritma dalam deep learning *feed-forward* yang memiliki kemampuan untuk mengenali pola dari data input yang besar [12]. Algoritma ini terdiri dari jaringan saraf yang dibangun dengan elemen yang disebut neuron, sementara penghubung antar neuron dikenal sebagai node. Node ini menghubungkan neuron dengan menambahkan bobot yang memengaruhi akurasi model. Jaringan ANN terdiri dari tiga lapisan, yaitu lapisan input, lapisan

tersembunyi (hidden layer), dan lapisan output. ANN menghasilkan kombinasi atribut secara linear dan mengubah keluaran menjadi non-linear berdasarkan atribut tersebut [13].

## 2.5 LSTM

Algoritma Long Short Term Memory (LSTM) merupakan algoritma *feedback-based model*, pengembangan dari algoritma Recurrent Neural Networks (RNN). Dalam algoritma RNN terdapat limitasi memory sehingga hanya dapat mundur beberapa tahap kebelakang. Hal ini menyebabkan adanya masalah dengan istilah *vanishing gradient*. Masalah ini terjadi ketika informasi tentang input yang melewati banyak layer hilang sebelum mencapai akhir atau awal dari layer. Masalah lain juga terjadi dengan istilah *exploding gradient*, yang merujuk ketika sebuah informasi melewati banyak layer akan terakumulasi dan menghasilkan sebuah gradient yang sangat besar ketika mencapai akhir atau awal dari layer.


Oleh karena itu, algoritma LSTM mengatasi masalah yang terjadi dalam algoritma RNN dengan memperpanjang memory. Dengan memperpanjang memory ini, LSTM dapat menyimpan dan mempelajari informasi jangka panjang. Informasi tersebut dapat ditulis, dibaca, dan dihapus tergantung dari keputusan yang terjadi. Keputusan ini dibuat berdasarkan bobot yang diletakkan dalam informasi dalam proses pelatihan.



**Gambar II.2** Arsitektur sel LSTM

Secara umum LSTM terdiri dari tiga gerbang yang dapat dilihat pada Gambar 2.2.

### 2.5.1 Forget Gate



**Gambar II.3 Forget Gate**

Forget Gate merupakan fungsi sigmoid yang digunakan gerbang untuk membuat keputusan tentang nilai yang harus dipertahankan atau nilai yang harus dihapus. Perhitungan forget gate dapat dilihat pada persamaan (2.1).

$$f_t = \sigma (W_{f_h}[h_{t-1}] W_{f_x}[x_t] b_f) \quad (2.1)$$

Keterangan persamaan (2.1):

$f_t$  = *forget gate*

$W_f$  = *bobot forget gate*


$h_{t-1}$  = *output sebelum waktu t*

$x_t$  = *output waktu t*

$b_f$  = *nilai bias forget gate*

Keputusan forget gate ( $f_t$ ) didasarkan pada input  $h_{t-1}$  dan  $x_t$  yang mengeluarkan hasil 0 atau 1 yang disimpan pada *cell state*. Angka 0 mengindikasikan bahwa nilai harus dihapus sedangkan angka 1 nilai harus disimpan.

### 2.5.2 Input Gate



**Gambar II.4 Input Gate**

Input Gate merupakan gerbang untuk membuat keputusan apakah nilai yang akan disimpan dalam *cell state*. Gerbang ini terdiri dari 2 layer yakni sigmoid layer ( $\sigma$ ) dan tanh layer. Sigmoid Layer memustuskan nilai yang akan diperbarui sementara itu tanh layer membuat vektor dari nilai yang akan ditambah kedalam *cell state*. Persamaan layer sigmoid dapat dilihat pada persamaan (2.2) dan layer tanh dapat dilihat pada persamaan (2.3).

$$i_t = \sigma (W_{i_h}[h_{t-1}] W_{i_x}[x_t] b_i) \quad (2.2)$$

Keterangan persamaan (2.2):

$i_t$  = *input gate*

$W_i$  = bobot *input gate*

$h_{t-1}$  = *output* sebelum waktu t

$x_t$  = *output* waktu t

$b_i$  = nilai bias *input gate*

$$\bar{C}_t = \tanh (W_{c_h}[h_{t-1}] W_{c_x}[x_t] b_c) \quad (2.3)$$

Keterangan persamaan (2.3):


$\bar{C}_t$  = calon nilai baru pada waktu t

$W_c$  = bobot *cell state*

$x_t$  = *output* waktu t

$h_{t-1}$  = *output* sebelum waktu t

$b_c$  = nilai bias *cell state*



**Gambar II.5 Cell State**

Kombinasi antara dua layer sigmoid dan tanh pada *input gate* membuat nilai saat ini dilupakan menggunakan forget gate yang dikalikan dengan nilai lama dan ditambahkan dengan nilai baru. Perhitungan ini dapat dilihat pada persamaan (2.4).

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \bar{C}_t \quad (2.4)$$

Keterangan persamaan (2.4):

$C_t$  = *cell state* pada waktu t


$f_t$  = *forget gate*

$C_{t-1}$  = *cell state* sebelum waktu t

$i_t$  = *input gate*

$\bar{C}_t$  = calon nilai baru pada waktu t

### 2.5.3 Output Gate



**Gambar II.6 Output Gate**

*Output gate* digunakan untuk menentukan bagian mana yang akan digunakan untuk keluaran. Selanjutnya, menghitung *cell state* melalui  $\tanh$  layer supaya menghasilkan nilai antara -1 dan 1. Selanjutnya hasil dari  $\tanh$  layer dikalikan dengan *output gate*. Perhitungan ini dapat dilihat pada persamaan (2.5) dan persamaan (2.6).

$$o_t = \tanh(W_{o_h}[h_{t-1}] W_{o_x}[x_t] b_o) \quad (2.5)$$

Keterangan persamaan (2.5):

$o_t$  = *output gate*

$W_o$  = bobot *output gate*

$x_t$  = *output* waktu t

$h_{t-1}$  = *output* sebelum waktu t

$b_o$  = nilai bias *output gate*

$$h_t = o_t \cdot \tanh(C_t) \quad (2.6)$$

Keterangan persamaan (2.6):

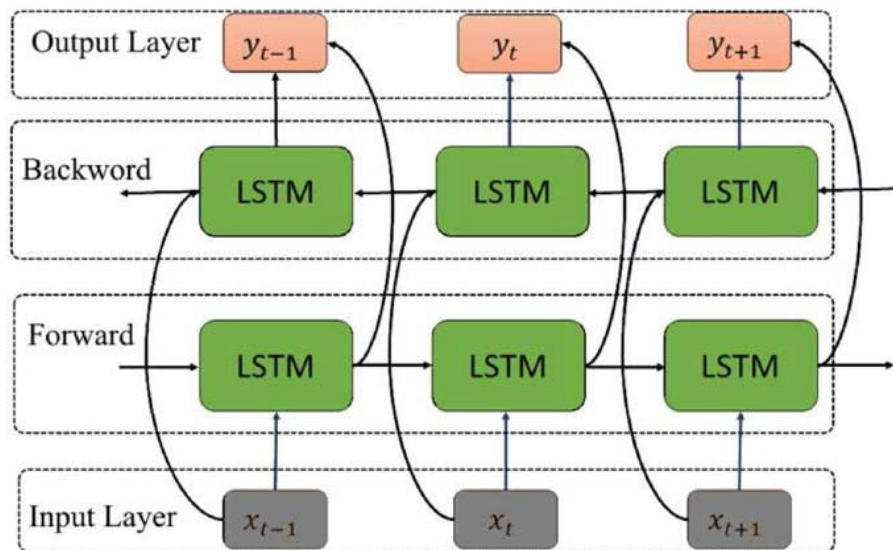
$h_t$  = nilai antara -1 dan 1

$o_t$  = *output gate*

$C_t$  = *cell state* pada waktu t

## 2.6 BiLSTM

Bidirectional Long Short Term Memory (BiLSTM) merupakan pengembangan dari algoritma Long Short Term Memory (LSTM). BiLSTM mengaplikasikan dua LSTM untuk input. Layer pertama digunakan untuk *forward* dan layer kedua digunakan untuk *backward*. Pengaplikasian dua layer digunakan untuk mempelajari data masa lalu dan data masa mendatang untuk setiap *sequence* input.

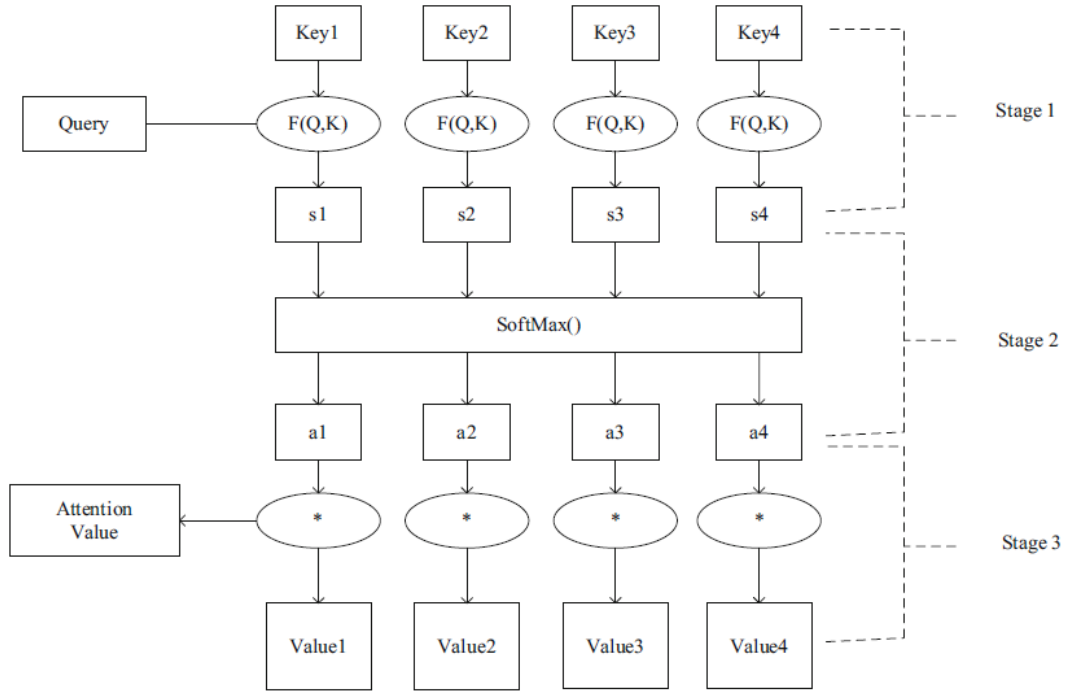


Gambar II.7 Arsitektur Bi-LSTM

## 2.7 Attention Mechanism

*Attention Mechanism* (AM) terinspirasi dari konsep manusia atau hewan untuk selektif dalam memberi perhatian lebih kepada sesuatu yang penting. Fokus kepada informasi yang penting dan membantu bahwa tidak ada sesuatu yang penting tertinggal. Dalam implementasinya AM memberikan bobot perhatian kepada sesuatu yang relevan dapat bertambah ataupun berkurang. Pada awalnya AM digunakan untuk Large Language Model (LLM) pada Natural Language Processing untuk memberikan ringkasan, menjawab pertanyaan, analisis sentimen, dan *text generation*. Meskipun awalnya digunakan untuk NLP, namun saat ini AM digunakan untuk analisis *time series* karena keduanya antara NLP dan *time series* memiliki ketergantungan terhadap data sebelumnya.





**Gambar II.8 Arsitektur Attention Mechanism**

Perhitungan attention mechanism terbagi menjadi tiga bagian, yaitu:

### 2.7.1 Attention Score Calculation

Hubungan antara Query (Output) dan Key (Input) dapat dilihat pada persamaan (2.7).

$$s_t = \tanh(W_h h_t + b_h) \quad (2.7)$$

### 2.7.2 Softmax Funcion

Score pada tahap 1 kemudian dinormalisasi menggunakan fungsi softmax. Perhitungan ini dapat dilihat pada persamaan (2.8)

$$a_t = \frac{\exp(s_t^T v)}{\sum_t \exp(s_t^T v)} \quad (2.8)$$

### 2.7.3 Attention Value Calculation

Proses ini menjumlahkan semua value dari setiap key yang berbeda, dapat dilihat pada persamaan (2.9).

$$s = \sum_t a_t h_t \quad (2.9)$$

## 2.8 Fungsi Aktivasi

Fungsi aktivasi ialah fungsi yang diaplikasikan untuk menentukan *output* dari *neuron*. Pada penelitian ini fungsi aktivasi yang digunakan, sebagai berikut:

### 2.8.1 Fungsi Linear

Fungsi linear mengembalikan nilai input tanpa perubahan. Fungsi ini digunakan dalam layer output regresi dengan nilai output yang diharapkan ialah nilai kontinuitas. Persamaan fungsi linear dapat dilihat pada persamaan (2.10).

$$f(x) = x \quad (2.10)$$

### 2.8.2 Fungsi ReLU

Rectified Linear Unit merupakan fungsi aktivasi populer yang mengembalikan nilai input jika positif dan nilai 0 jika negatif. ReLU membantu untuk mengatasi masalah *vanishing gradient* dan mempercepat pelatihan. Persamaan fungsi ReLU dapat dilihat pada persamaan (2.11)

$$f(x) = \max(0, x) \quad (2.11)$$

### 2.8.3 Fungsi Sigmoid

Fungsi aktivasi sigmoid digunakan dalam layer output untuk klasifikasi biner. Fungsi sigmoid mengubah nilai input menjadi nilai dengan rentang antara 0 dan 1. Persamaan fungsi sigmoid dapat dilihat pada persamaan (2.12)

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.12)$$

### 2.8.4 Fungsi Tanh

Fungsi tanh atau *hyperbolic tangent* ialah fungsi yang lebih baik dari fungsi sigmoid dalam konvergensi karena terpusat pada nilai 0. Fungsi tanh mengubah nilai input menjadi nilai dengan rentang antara -1 dan 1. Persamaan fungsi sigmoid dapat dilihat pada persamaan (2.13)

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.13)$$

## 2.9 Metrik Evaluasi

Metrik evaluasi digunakan untuk menilai kinerja model setelah dilatih. Metrik membantu dalam menganalisis seberapa baik model dalam melakukan prediksi. Berikut metrik evaluasi yang digunakan dalam penelitian ini:

### 2.9.1 Mean Absolute Error

Mean Absolute Error (MAE) merupakan metrik yang mengukur rata-rata antara nilai prediksi dengan nilai aktual. Namun terdapat kekurangan yaitu tidak dapat mengetahui apakah model *under predicting* atau *over predicting*. Persamaan MAE dapat dilihat pada persamaan (2.14)

$$MAE = \frac{1}{N} \sum_{j=1}^N |y_j - \hat{y}_j| \quad (2.14)$$

### 2.9.2 Mean Squared Error

Mean Squared Error (MSE) merupakan metrik yang sama seperti MAE, namun dengan perbedaan yaitu menghitung kuadrat dari rata-rata antara nilai prediksi dengan nilai aktual. Persamaan MAE dapat dilihat pada persamaan (2.15)

$$MSE = \frac{1}{N} \sum_{j=1}^N (y_j - \hat{y}_j)^2 \quad (2.15)$$

### 2.9.3 Root Mean Squared Error

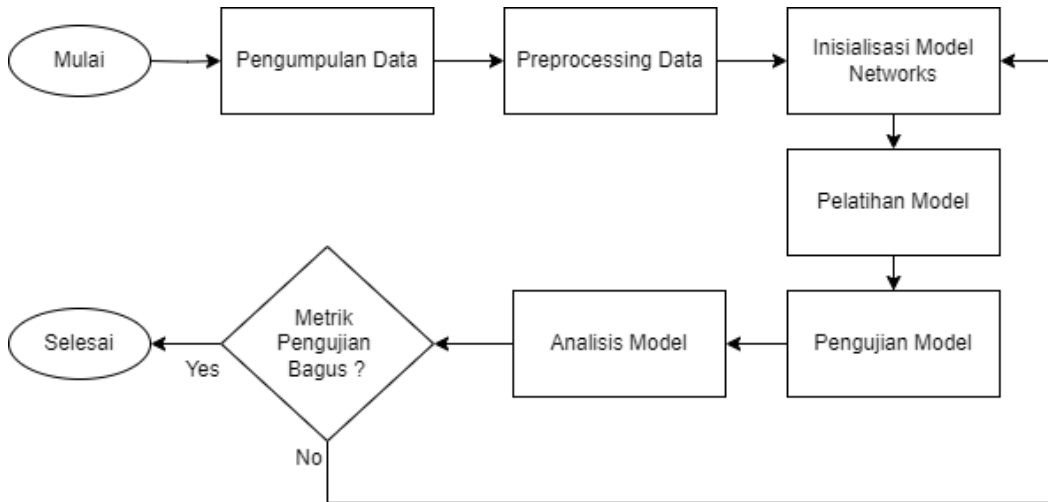
Root Mean Squared Error (RMSE) merupakan metrik MSE yang diakar kuadrat. Penambahan akar kuadrat memberikan bobot yang lebih tinggi terhadap kesalahan besar dalam prediksi. Persamaan MAE dapat dilihat pada persamaan (2.16)

$$RMSE = \sqrt{\frac{1}{N} \sum_{j=1}^N (y_j - \hat{y}_j)^2} \quad (2.16)$$

## BAB III METODOLOGI

### 3.1 Prosedur Penelitian

Penelitian ini dilakukan dengan menggunakan metode *Bidirectional Long Short Term Memory* (Bi-LSTM) dan *Attention Mechanism* yang terdiri dari lima tahapan penelitian. Tahapan penelitian dapat dilihat pada gambar 3.1.

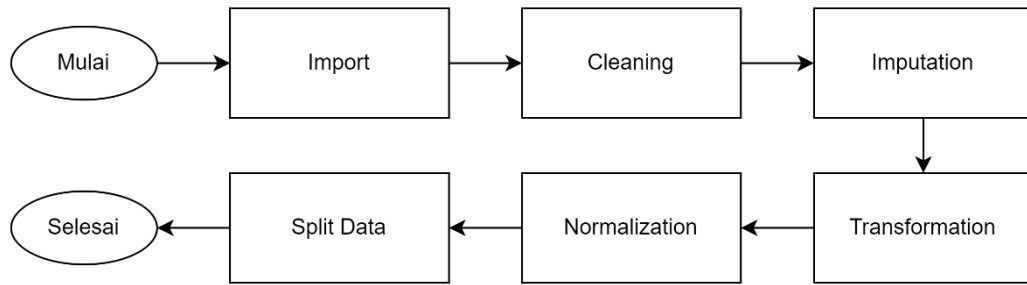


**Gambar III.1 Diagram alir prosedur penelitian**

### 3.2 Pengumpulan Data

Dalam penelitian ini terdapat 6 fitur yang digunakan, yaitu nilai kurs pembukaan, nilai kurs penutupan, suku bunga Bank Indonesia (BI), nilai impor, dan nilai ekspor. Informasi kurs seperti nilai pembukaan dan penutupan diambil dari situs *investing.com* yang merupakan situs finansial *real-time* yang didirikan pada tahun 2007. *Investing.com* mencakup lebih dari 300.000 instrumen finansial termasuk pasar saham, mata uang dunia, obligasi, reksadana, dan suku bunga. Data ekspor, impor, dan suku bunga BI diambil dari situs Badan Pusat Statistik (*bps.go.id*). Satuan nilai untuk masing-masing fitur, yaitu nilai kurs dinyatakan dalam ribu rupiah, volume ekspor dan impor dinyatakan dalam ribu ton, nilai ekspor dan impor dinyatakan dalam juta USD, dan suku bunga BI dinyatakan dalam persen.


### 3.3 Preprocessing Data



**Gambar III.2 Diagram alir preprocessing data**

Sebelum dilakukan analisis, data perlu diproses supaya mendapat hasil yang maksimal. Tahap pertama ialah *cleaning* data dalam artian membersihkan data dari nilai kosong. Selanjutnya pada tahap *imputation* yang merupakan tahap untuk mengisi kekosongan data atau menambahkan fitur baru berdasarkan fitur yang sudah ada. *Imputation* dapat berupa operasi *mean*, *median*, *high*, dan *low*. Setelah itu, tahap *transformation* ialah mengubah seluruh tipe data menjadi float dan tipe data tanggal menjadi *datetime*. Setelah itu mengubah fitur tanggal menjadi index. Dengan mengubah tanggal menjadi index dapat mempermudah analisis data *time series*. Selanjutnya pada tahap *normalization* ialah mengubah data dalam skala yang sama. Tahap terakhir ialah membagi data antara data latih dan data uji dengan skala yang ditentukan.

### 3.4 Inisialisasi Jaringan Model

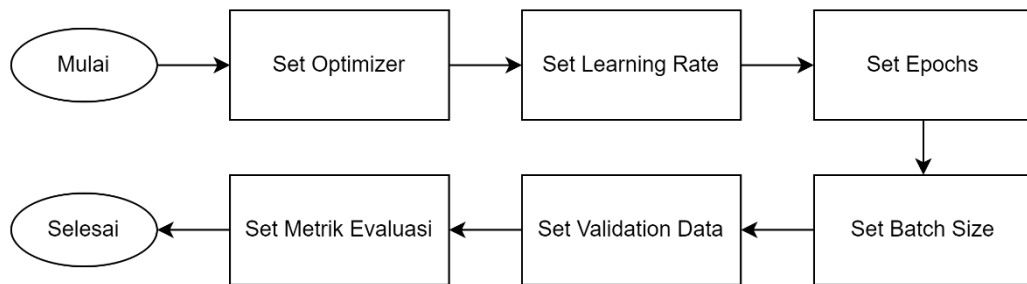


**Gambar III.3 Jaringan model BiLSTM-Attention**

Pada gambar 3.3 memperlihatkan struktur jaringan model BiLSTM dan AM pada penelitian ini. Proses ini dilakukan secara sekuensial yaitu setiap elemen mengikuti elemen sebelumnya. Proses dimulai dengan layer BiLSTM dengan memasukkan jumlah *neuron* dan *input shape*, *input shape* berupa array tiga dimensi berisi jumlah sampe, jumlah timestep, dan jumlah fitur. Antara layer BiLSTM terdapat *dropout layer*; tugas dari *dropout layer* ialah menonaktifkan beberapa

*neuron* untuk mengurangi *overfitting*. Setelah *dropout layer* pertama dilanjutkan BiLSTM *layer* kedua, proses ini sama seperti BiLSTM *layer* pertama dan dilanjutkan dengan *dropout layer*. Selanjutnya *attention layer* dengan input shape array tiga dimensi berisi jumlah sampel, timestep, dan jumlah *unit* dengan output *attention layer* ialah array dua dimensi berisi jumlah sampel dan *unit*. Layer terakhir ialah *dense* digunakan untuk menghasilkan nilai prediksi dari model.

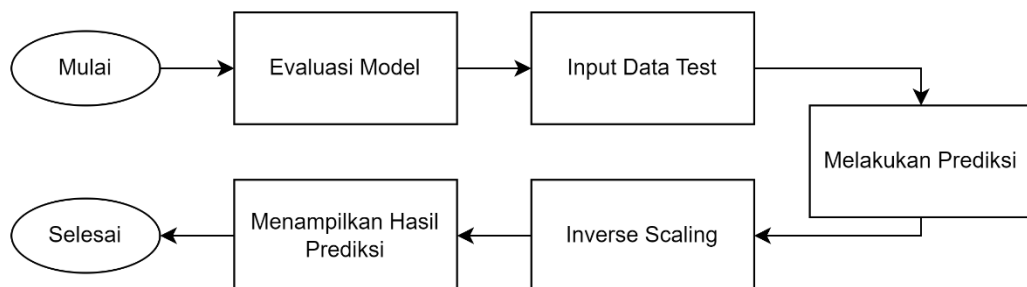
### 3.5 Pelatihan Model



**Gambar III.4 Diagram alir pelatihan model**

Setelah inisialisasi jaringan model, langkah selanjutnya adalah pelatihan model. Proses ini melibatkan penggunaan data latih yang telah diproses sebelumnya. Model akan dilatih dengan struktur yang sudah diinisiasi di awal. Selama pelatihan, model akan dilatih dengan beberapa skema pelatihan. Proses ini bertujuan untuk mencari arsitektur dengan nilai error terkecil sehingga model baik dalam memprediksi output yang diinginkan.

### 3.6 Evaluasi dan Pengujian Model



**Gambar III.5 Diagram alir evaluasi dan pengujian model**

Setelah model dilatih, tahap berikutnya adalah evaluasi model menggunakan metrik evaluasi yang sudah ditentukan. Pada penelitian ini evaluasi

dilakukan dengan metode Mean Squared Error (MSE), Mean Absolute Error (MAE), dan Mean Absolute Percentage Error (MAPE), evaluasi dilakukan untuk menilai kinerja model. Setelah model dievaluasi, akan dilakukan tahap pengujian. Pada tahap pengujian, model akan menghasilkan prediksi berdasarkan input dari data uji, dan hasilnya akan dibandingkan dengan data yang sebenarnya.

### **3.7 Analisis Hasil Pengujian**

Setelah pengujian model, analisis hasil menjadi tahapan untuk memahami kinerja model secara keseluruhan. Visualisasi menggunakan grafik digunakan untuk menggambarkan performa model, seperti grafik *plot scatter*, grafik nilai prediksi dengan nilai aktual.

## DAFTAR PUSTAKA

- [1] K. Samosir and S. Arka, “Fluktuasi Nilai Tukar Rupiah Atas Dolar AS,” *Jurnal Review Pendidikan dan Pengajaran*, vol. 7, no. 3, pp. 10431–10441, Jul. 2024.
- [2] F. Ardiya Garini, “PERGERAKAN NILAI TUKAR RUPIAH TERHADAP EKSPOR DAN IMPOR INDONESIA,” 2020.
- [3] V. Nathania, A. Rizky Ramadhanti, and Trimono, “Pengaruh Nilai Tukar Rupiah terhadap Dolar Amerika Serikat dengan Jumlah Wisatawan Asia Tenggara,” in *Seminar Nasional Sains Data*, 2023, pp. 190–199.
- [4] A. Kartono, M. Febriyanti, S. T. Wahyudi, and Irmansyah, “Predicting foreign currency exchange rates using the numerical solution of the incompressible Navier–Stokes equations,” *Physica A: Statistical Mechanics and its Applications*, vol. 560, p. 125191, Dec. 2020, doi: 10.1016/J.PHYSA.2020.125191.
- [5] A. Devi and P. Hendikawati, “Prediksi Kurs Rupiah Terhadap Dolar dengan Menggunakan Model LSTM,” in *Prosiding Seminar Nasional Matematika*, 2024, pp. 882–891. [Online]. Available: <https://proceeding.unnes.ac.id/prisma>
- [6] Ely Ermawati, Miftakhul Aziz, Fanja Rahayu Estetika, and Sukma Ardiyanti, “Pengaruh Inflasi, Suku Bunga, Produk Domestik Bruto Terhadap Nilai Tukar Rupiah Tahun 2018-2022,” *OPTIMAL Jurnal Ekonomi dan Manajemen*, vol. 4, no. 1, pp. 218–229, Dec. 2023, doi: 10.55606/optimal.v4i1.2641.
- [7] E. Amitha Mutiara and D. Puspitasari, “Pengaruh Inflasi, Ekspor dan Impor Terhadap Stabilitas Nilai Tukar Rupiah per Dollar AS Periode 2016-2022,” *Jurnal Simki Economic*, vol. 7, no. 1, pp. 50–62, 2024, [Online]. Available: <https://jipied.org/index.php/JSE>
- [8] S. Liu, Q. Huang, M. Li, and Y. Wei, “A new LASSO-BiLSTM-based ensemble learning approach for exchange rate forecasting,” *Eng Appl Artif Intell*, vol. 127, p. 107305, Jan. 2024, doi: 10.1016/j.engappai.2023.107305.
- [9] W. Lu, J. Li, J. Wang, and L. Qin, “A CNN-BiLSTM-AM method for stock price prediction,” May 01, 2021, *Springer Science and Business Media Deutschland GmbH*. doi: 10.1007/s00521-020-05532-z.
- [10] X. Xu, Y. Zhang, C. A. McGrory, J. Wu, and Y. G. Wang, “Forecasting stock closing prices with an application to airline company data,” *Data Science and Management*, vol. 6, no. 4, pp. 239–246, Dec. 2023, doi: 10.1016/j.dsm.2023.09.005.



- [11] J. E. Hanke and D. Wichern, *Business Forecasting*. 2005.
- [12] D. Y. Descania, “Prediksi Pertumbuhan Penduduk Di Kecamatan Baregbeg Kabupaten Ciamis Menggunakan Metode Artificial Neural Network,” *Jurnal Informatika dan Teknologi Pendidikan*, vol. 2, no. 2, pp. 37–43, Dec. 2022, doi: 10.25008/jitp.v2i2.28.
- [13] Satrio Junaidi, R. Valicia Anggela, and D. Kariman, “Klasifikasi Metode Data Mining untuk Prediksi Kelulusan Tepat Waktu Mahasiswa dengan Algoritma Naïve Bayes, Random Forest, Support Vector Machine (SVM) dan Artificial Neural Network (ANN),” *Journal of Applied Computer Science and Technology*, vol. 5, no. 1, pp. 109–119, Jun. 2024, doi: 10.52158/jacost.v5i1.489.